MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Formativa 2

Práctica de Modelamiento Predictivo

Informe de práctica grupal · sin ponderación (formativa)

Título del proyecto:	Evaluación del riesgo de deserción frente a graduación
Integrantes:	Grupo 8: Matias Manriquez Ortiz, Daniel Pérez Ramírez, Abigaíl Robles Chávez, Roberto Sánchez Saldivia
Dataset:	Predict Students' Dropout and Academic Success (UCI, 2021)
Docente:	Jean Paul Maidana Gonzalez
Fecha:	22/10/2026
Repositorio GitHub:	https://github.com/MatiasManriquezO/MCDI501-grupo8

Información de la evaluación	
Fase:	3: Desarrollo (práctica previa a la Fase 4)
Ponderación:	0 % (formativa, con retroalimentación)
Entregables:	Notebook .ipynb ejecutable · este informe breve (opcional)
Resultado de aprendizaje:	RA3 (se practica).
Prerrequisitos:	Sumativas 1 y 2.

Conexión con evaluaciones anteriores

Esta práctica reutiliza los hallazgos de S1 (análisis exploratorio e inferencial) y S2 (validación por remuestreo) para construir un primer modelo de clasificación sobre la base de deserción del grupo. Es una versión simplificada: un solo modelo logístico, imputación simple y sin bootstrap. Su propósito es ensayar el flujo completo de modelamiento y recibir retroalimentación antes de la Sumativa 3, identificando errores a tiempo.

Índice

1. Preparación de datos para el modelamiento 2
1.1. Referencia a los hallazgos de S1 y S2 2
1.2. Tratamiento de datos y partición 2
2. Modelo de regresión logística 3
2.1. Selección de variables 3
2.2. Ajuste e interpretación de coeficientes 4
2.3. Diagnóstico de multicolinealidad 4
3. Evaluación de desempeño 5
3.1. Matriz de confusión y métricas 5
3.2. Curva ROC y AUC 5
4. Síntesis y reflexión 6
5. Bibliografía 7

1. Preparación de datos para el modelamiento

1.1. Referencia a los hallazgos de S1 y S2

El punto de partida de esta formativa no es el dato crudo, sino el conocimiento acumulado en las dos sumativas previas. En S1 se caracterizó el conjunto *Predict Students' Dropout and Academic Success* (Realinho et al., 2021), con 4.424 estudiantes de pregrado de una institución de educación superior de Portugal. El proyecto trabaja con *Dropout* frente a *Graduate*, sin los 794 estudiantes *Enrolled* (su desenlace aún no se conoce) ni 152 registros sin ninguna actividad académica en dos semestres, lo que deja **3.478 estudiantes y 38,6 % de desertores** (1.344). A diferencia de un problema de fraude o morosidad, el desbalance de clases es moderado.

S1 identificó además faltantes generados al azar (MCAR) en la nota de admisión (12,6 %) y en la edad al ingresar (11,7 %), notas de semestre iguales a 0 que en realidad significan "sin nota" y una edad muy asimétrica (asimetría 1,97; mediana 20 años frente a media 23,6). Como señales de riesgo destacó el desempeño del primer año —unidades aprobadas del 2.º semestre (r = −0,69) y su nota (r = −0,33)—, la edad (r = +0,29) y la beca (deserta el 13,1 % de los becados y el 48,0 % de quienes no tienen beca).

S2 aportó la validación de esas señales. Mediante *bootstrap* verificó cuáles correlaciones eran estables, es decir, cuáles mantenían su signo y magnitud al recalcularse sobre 10.000 remuestras. Las de unidades aprobadas del 2.º semestre (r = −0,69 [−0,71; −0,66]), nota del 2.º semestre (r = −0,33 [−0,37; −0,30]) y edad (r = 0,29 [0,25; 0,32]) resultaron estables. La tasa de desempleo resultó inestable (IC [−0,04; 0,03] incluye el cero) y las unidades aprobadas de ambos semestres mostraron una multicolinealidad real (r = 0,91 [0,90; 0,92]). La permutación de S2 confirmó además la asociación entre beca y deserción (p = 0,0001). Esta distinción guía, más abajo, la selección de variables: no se eligen por intuición, sino por evidencia validada.

1.2. Tratamiento de datos y partición

Se parte de la versión con faltantes de S1 (data_con_faltantes.csv) y se mantienen sus decisiones: *Dropout* frente a *Graduate*, exclusión de los 152 registros sin actividad y nota de semestre igual a 0 tratada como "sin nota". Siguiendo la recomendación de S1 y S2, la edad se transforma con logaritmo por su asimetría y su cola de hasta 70 años.

Sobre los valores faltantes, y dado que esta es una evaluación formativa orientada a ensayar el flujo, se adoptó una estrategia simple: la **imputación por la mediana**. Es una elección razonable porque es robusta a la asimetría de la edad (una media se vería arrastrada por la cola de estudiantes mayores) y porque preserva el tamaño completo de la muestra. Como los faltantes de la edad son MCAR, la imputación no introduce sesgo de selección (Little y Rubin, 2019). La mediana se calcula **solo con el conjunto de entrenamiento** y luego se aplica al de prueba, para que ninguna información de prueba entre al ajuste.

La limitación conocida es que imputar con una constante reduce artificialmente la variabilidad. Al compararla con los valores originales que S1 guardó, la mediana (20 años) comete un error absoluto medio de 5,02 años en las 406 edades perdidas, y la desviación estándar de la edad baja de 7,92 a 7,53. Además, los 650 faltantes de la nota del 2.º semestre **no son aleatorios**: corresponden exactamente a estudiantes con 0 unidades aprobadas, y la mediana les asigna una nota que no tuvieron. Ambos costos se asumen en esta fase y se abordan con mayor rigor en S3.

La partición se hizo en un 70 % de entrenamiento (2.434 estudiantes) y un 30 % de prueba (1.044), estratificada por la variable objetivo, con semilla 42. La estratificación conserva

la proporción de desertores en ambos subconjuntos (38,7 % y 38,6 %). Por último, las variables continuas se estandarizaron (media cero, desviación uno), de modo que sus *odds ratios* se interpreten por desviación estándar y sean comparables entre sí; la beca, que es binaria, se dejó en 0/1. La Figura 1 ilustra, para dos de las variables, por qué separan bien las clases: casi la mitad de los desertores no aprueba ninguna unidad en el 2.º semestre, mientras que los graduados se concentran entre 5 y 8; la edad muestra un patrón más suave, con los desertores más presentes sobre los 22 años.

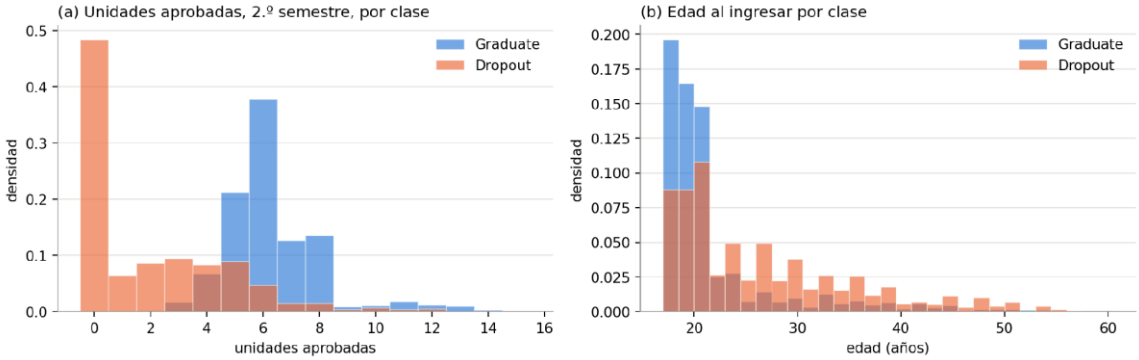


Figura 1. Distribución de dos predictores por clase. (a) Unidades aprobadas del 2.º semestre. (b) Edad al ingresar (valores observados).

2. Modelo de regresión logística

2.1. Selección de variables

A partir de la matriz de correlaciones de S1 y su validación en S2, se seleccionaron cuatro predictores (Tabla 1). El criterio fue doble: que la variable mostrara una asociación relevante con la deserción en S1 y que esa asociación resistiera la validación de S2. Es la lógica de selección informada por el dominio que el apunte del curso plantea como uno de los enfoques válidos de selección de variables.

Tabla 1. Variables seleccionadas y el hallazgo de S1/S2 que respalda cada una.

Variable	Corr. S1	Validación S2	Fundamento
Unidades aprobadas, 2.º sem	−0,69	IC [−0,71; −0,66]	Asociación más fuerte y más estable; señal para priorizar tutorías al cierre del primer año.
Nota 2.º sem. (sin ceros)	−0,33	IC [−0,37; −0,30]	Aporta la calidad del desempeño, además de la cantidad de unidades aprobadas.
Edad (logaritmo)	+0,29	IC [0,25; 0,32]	Los estudiantes mayores desertan más; se transforma por su asimetría.
Beca	V = 0,32 (Prueba 3)	Permutación p = 0,0001	Variable de apoyo financiero: deserta el 13,1 % con beca y el 48,0 % sin ella.

Quedaron fuera las **unidades aprobadas del 1.er semestre**, porque S2 mostró que correlacionan r = 0,91 con las del 2.º semestre y se prioriza la más fuerte y estable; la **tasa de desempleo**, por su correlación inestable (IC que incluye el cero); y la **nota de admisión**, que S2 no validó como correlación estable con la deserción y queda para la comparación de modelos de S3. Una precisión: S2 no calculó un IC *bootstrap* para la beca, por lo que se incorpora respaldada por la Prueba 3 y su permutación, no por una correlación validada.

La **matrícula al día** también se dejó fuera, porque S1 advirtió que puede ser consecuencia del abandono (quien decide desertar deja de pagar), lo que sería una fuga de información. Como sensibilidad, se ajustó el modelo con ella usando la misma partición: el AUC

sube de 0,925 a 0,933 y el recall pasa de 0,814 a 0,816, una mejora mínima, mientras que su odds ratio es extremo (OR ≈ 0,04: con la matrícula al día, las odds de desertar son 96 % menores). Como el modelo busca anticipar la deserción, se mantiene fuera del modelo principal.

2.2. Ajuste e interpretación de coeficientes

El modelo se ajustó con la biblioteca *statsmodels* (Seabold y Perktold, 2010) sobre las variables preparadas, agregando una constante. La interpretación de los *odds ratios* es el corazón del análisis, porque traduce los coeficientes a un lenguaje de decisión (Tabla 2).

Tabla 2. Coeficientes, odds ratios (OR) e intervalos de confianza al 95 % (entrenamiento, n = 2.434).

Variable	Coeficiente	OR	IC 95 % del OR	p
Constante	−0,513	0,599	[0,518; 0,692]	< 0,001
Unidades aprobadas, 2.º sem.	−2,458	0,086	[0,069; 0,106]	< 0,001
Nota 2.º sem.	−0,372	0,689	[0,606; 0,784]	< 0,001
Edad (logaritmo)	+0,337	1,401	[1,231; 1,593]	< 0,001
Beca (sí = 1)	−1,106	0,331	[0,240; 0,456]	< 0,001

Las **unidades aprobadas del 2.º semestre** son el mayor factor de protección: cada desviación estándar adicional (≈ 3,1 unidades) reduce las odds de deserción en ≈ 91 % (OR ≈ 0,09); por unidad adicional, el OR es ≈ 0,45. Esto coincide con S1 y con el IC estrecho de S2. La **nota del 2.º semestre** aporta de forma independiente: a igualdad de unidades aprobadas, una desviación estándar más (≈ 1,26 puntos) reduce las odds en ≈ 31 %. La **edad** actúa como factor de riesgo: una desviación estándar del logaritmo equivale a multiplicar la edad por ≈ 1,30 (por ejemplo, de 20 a 26 años) y sube las odds en ≈ 40 %. La **beca**, al ser binaria, compara becados con no becados: a igualdad del resto, los becados tienen ≈ 67 % menos odds de desertar, aunque al ser una asociación observacional no prueba que la beca evite la deserción.

Las cuatro variables resultan estadísticamente significativas ($p < 0{,}001$) y el pseudo R^2 de McFadden es ≈ 0,52, un ajuste muy bueno para un modelo de cuatro variables.

2.3. Diagnóstico de multicolinealidad

Un supuesto que conviene verificar en toda regresión con varios predictores es la ausencia de multicolinealidad, es decir, que las variables no estén tan correlacionadas entre sí como para volver inestables los coeficientes. Se calcularon los factores de inflación de varianza (VIF) de las cuatro variables: 1,12 para las unidades aprobadas, 1,06 para la nota, 1,08 para la edad y 1,09 para la beca. Todos quedan muy por debajo del umbral habitual de 5 (James et al., 2013), lo que descarta cualquier problema de colinealidad.

Este resultado no es casual. La advertencia de S1 y S2 ($r = 0{,}91$ entre las unidades aprobadas de ambos semestres) implicaría un VIF teórico de ≈ 5,7 solo con esas dos variables, y se resolvió **antes** de ajustar, al dejar únicamente las del 2.º semestre.

3. Evaluación de desempeño

3.1. Matriz de confusión y métricas

Con un umbral de decisión de 0,5, el modelo alcanza una *accuracy* de 89,5 % sobre el conjunto de prueba (1.044 estudiantes, 403 desertores). A diferencia de un problema con clases muy desbalanceadas, aquí la *accuracy* sí es informativa: el desbalance es moderado y un clasificador trivial que predijera "nadie deserta" alcanzaría solo 61,4 %. Aun así, no basta por sí sola, porque no distingue el tipo de error. Por eso el análisis se apoya también en la *precisión*, el *recall* y su media armónica, el *F1-score* (Tabla 3), calculadas para la clase *Dropout*.

Tabla 3. Métricas de desempeño en el conjunto de prueba (umbral 0,5; clase positiva = Dropout).

Métrica	Valor	Lectura
Accuracy	0,895	Casi nueve de cada diez estudiantes bien clasificados (trivial: 0,614).
Precisión	0,904	De 363 estudiantes marcados en riesgo, 328 desertan realmente y 35 no.
Recall	0,814	Detecta 328 de los 403 desertores reales; 75 quedan sin alerta.
F1-score	0,856	Balance entre precisión y recall de la clase Dropout.
AUC	0,925	Capacidad de ordenar desertores sobre graduados, independiente del umbral.

En este contexto el *recall* es la métrica crítica. S1 plantea una asimetría de costos: no detectar a un estudiante en riesgo cuesta más que apoyar a quien no lo necesitaba. Es decir, un falso negativo (un desertor sin alerta) es más costoso que un falso positivo (un estudiante apoyado sin necesitarlo). La Figura 2 muestra que el modelo comete 35 falsos positivos y 75 falsos negativos: con umbral 0,5 es algo conservador al marcar riesgo, y esos 75 desertores sin alerta son el principal margen de mejora.

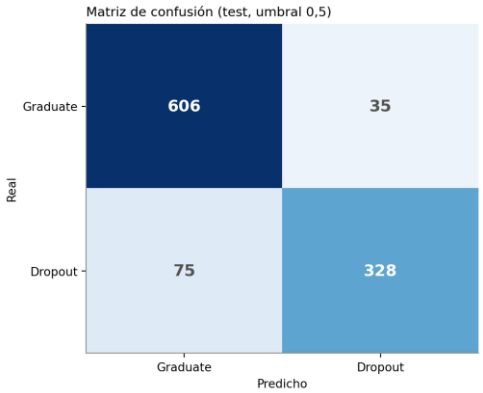


Figura 2. Matriz de confusión sobre el conjunto de prueba (umbral 0,5). Las filas son la clase real y las columnas la clase predicha.

3.2. Curva ROC y AUC

La métrica que resume la capacidad discriminante del modelo, y que no depende del umbral elegido, es el área bajo la curva ROC (AUC). El valor obtenido, **0,925**, sitúa al modelo en el rango excelente (> 0,9) según la escala habitual (Hosmer et al., 2013). Su interpretación es intuitiva: si se toman al azar un estudiante que desertó y uno que se graduó, el modelo asigna mayor probabilidad de deserción al primero aproximadamente el 92,5 % de las veces. La curva (Figura 3) se aleja con claridad de la diagonal del clasificador aleatorio.

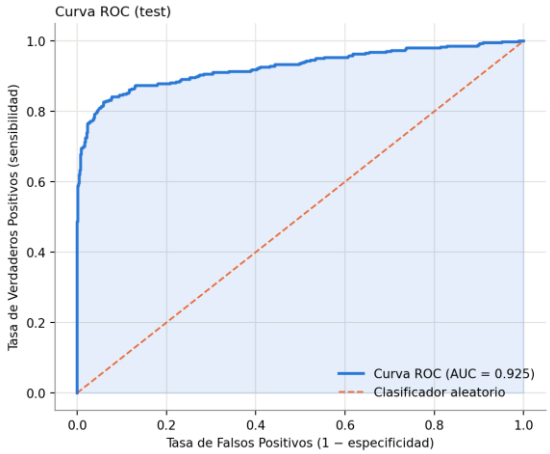


Figura 3. Curva ROC sobre el conjunto de prueba. El área bajo la curva (AUC) resume la capacidad del modelo para distinguir desertores de graduados, independientemente del umbral.

Una cautela: gran parte del poder predictivo proviene de las unidades aprobadas del 2.º semestre, y un estudiante que abandona a mitad de semestre termina con pocas o ninguna unidad aprobada. Parte de la señal puede ser, entonces, consecuencia del abandono y no solo un aviso previo. Por eso el modelo sirve para priorizar tutorías al cierre del primer año, pero no para detectar la deserción antes de que ocurra.

4. Síntesis y reflexión

Esta práctica permitió recorrer el flujo completo de modelamiento predictivo que la Sumativa 3 pide en su forma extendida: preparar los datos apoyándose en los hallazgos previos, seleccionar variables con fundamento, ajustar un modelo de clasificación, interpretar sus coeficientes en clave de decisión, diagnosticar sus supuestos y evaluar su desempeño con las métricas adecuadas.

La **conexión con S1** se vio en la selección de variables y en el tratamiento de datos: las señales de riesgo (desempeño del primer año, edad y beca), los faltantes MCAR, la exclusión de los 152 registros sin actividad, la nota 0 como "sin nota" y la transformación de la edad no se redescubrieron, sino que se heredaron del análisis exploratorio. La **conexión con S2** dio solidez a esas decisiones: la validación por *bootstrap* distinguió las correlaciones estables de la inestable (desempleo), advirtió la multicolinealidad entre las unidades aprobadas de ambos semestres (resuelta, con VIF ≤ 1,12) y la permutación respaldó la inclusión de la beca.

En cuanto al desempeño, la valoración es positiva con matices. El AUC de 0,925 muestra una capacidad discriminante excelente y la *accuracy* (89,5 %) supera con holgura al clasificador trivial (61,4 %). Sin embargo, el *recall* de 81,4 % deja a 75 de 403 desertores sin alerta, el error más costoso en una decisión de tutorías, y parte de la señal puede ser consecuencia del abandono. El principal aprendizaje fue que una métrica alta no basta: hay que revisar el tipo de error y si el predictor principal es causa o consecuencia del fenómeno.

Para la Sumativa 3 quedan identificadas cuatro mejoras. Primero, reemplazar la imputación por mediana con imputación por regresión y comparar estrategias, incluyendo un indicador "sin nota". Segundo, construir y comparar tres modelos con criterios de selección distintos (incorporando, por ejemplo, la nota de admisión y las variables financieras y demográficas). Tercero, aplicar *bootstrap* a los coeficientes para cuantificar su estabilidad. Y cuarto, usar ponderación por clase y ajustar el umbral para mejorar el *recall*. La progresión S1

→ S2 → S3 queda así encaminada, y está formativa (y su cuaderno) constituye la base directa del proyecto final integrado.

5. Bibliografía

Hosmer, D. W., Lemeshow, S. y Sturdivant, R. X. (2013). *Applied logistic regression* (3.ª ed.). Wiley.

James, G., Witten, D., Hastie, T. y Tibshirani, R. (2013). *An introduction to statistical learning*. Springer.

Little, R. J. A. y Rubin, D. B. (2019). *Statistical analysis with missing data* (3.ª ed.). Wiley.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Realinho, V., Vieira Martins, M., Machado, J. y Baptista, L. (2021). Predict students' dropout and academic success [Conjunto de datos]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success

Seabold, S. y Perktold, J. (2010). statsmodels: Econometric and statistical modeling with Python. En *Proceedings of the 9th Python in Science Conference* (pp. 92–96).