Universidad Andrés Bello

MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 1

Análisis Exploratorio e Inferencial

Título del proyecto:	Deserción y éxito académico en educación superior
Integrantes:	Matias Manriquez Ortiz, Daniel Pérez Ramirez, Abigail Robles Chávez, Roberto Sánchez Saldivia
Dataset:	Predict Students' Dropout and Academic Success (UCI, 2021)
Docente:	Jean Paul Maidana Gonzalez
Fecha:	14/10/2026
Repositorio GitHub:	https://github.com/MatiasManriquezO/MCDI501-grupo8

Información de la evaluación	
Fase del proyecto:	Fase 2: Búsqueda y recopilación de información
Modalidad:	Grupal (3-4 integrantes)
Ponderación:	20 % de la nota final
Entregables:	Informe PDF (máx. 8 págs., sin anexos) · Notebook .ipynb · Repositorio GitHub
Resultado de aprendizaje:	RA1: aplicar probabilidad e inferencia estadística en problemas de decisión bajo incertidumbre.
Indicadores:	ID1.2, ID1.3, ID1.4
Recuerden:	Los resultados de esta sumativa serán la entrada de S2 y S3.

Índice

Índice....2
I. Preparación y carga de datos....3
II. Análisis exploratorio de datos....4
A. Variables numéricas.... 4
B. Variables categóricas....4
C. Análisis bivariado....5
III. Estimación de parámetros....6
IV. Pruebas de hipótesis....6
A. Prueba 1: unidades aprobadas en el 2° semestre.... 6
B. Prueba 2: matrícula al día y deserción.... 7
C. Prueba 3: beca y deserción....7
V. Informe de avance del proyecto....7
VI. Notebook y repositorio GitHub....8
VII. Bibliografía....8

I. Preparación y carga de datos

El proyecto usa el conjunto **Predict Students' Dropout and Academic Success** (Realinho et al., 2021): 4.424 estudiantes de pregrado de una institución de educación superior de Portugal, descritos por 36 variables demográficas, socioeconómicas, macroeconómicas y de desempeño en los dos primeros semestres, más la variable Target. El archivo se cargó con pandas (separador punto y coma); pandas lee 29 columnas como enteros, 7 como decimales y Target como texto. Se eliminó un tabulador presente al final del nombre de una columna.

Decisiones del proyecto. Target tiene tres clases. Siguiendo el apunte del curso (Maidana, 2026), que pide seleccionar dos, se trabaja con **Dropout (1) frente a Graduate (0)** y se excluyen los 794 estudiantes Enrolled, cuyo desenlace aún no se conoce. Como el conjunto viene completo, el mismo apunte exige generar faltantes antes de analizar: se eliminó al azar (MCAR) el 12 % de la nota de admisión y de la edad al ingresar, con semilla 42, guardando los valores originales.

Tipos de variables. Aunque todas se almacenan como números, 18 de las 36 variables son categorías codificadas: 8 binarias (jornada, desplazado, necesidades educativas especiales, deudor, matrícula al día, sexo, becado, internacional), 1 ordinal (orden de postulación) y 9 nominales (estado civil, modalidad de postulación, carrera, formación previa, nacionalidad, y nivel educativo y ocupación de los padres). Las cuantitativas son 7 continuas (notas de admisión, de formación previa y de cada semestre; desempleo, inflación y PIB) y 11 discretas (edad y unidades curriculares de cada semestre).

Tabla 1. Reporte de calidad de los datos.

Revisión	Casos	%	Tratamiento
Sin unidades inscritas, acreditadas ni evaluadas en ambos semestres	152	4,2	Se excluyen (77 Dropout, 75 Graduate)
Filas duplicadas	0	0,0	No requiere
Faltantes en nota de admisión (MCAR)	437	12,6	Casos disponibles; imputación en la Sumativa 3
Faltantes en edad al ingresar (MCAR)	406	11,7	Casos disponibles; imputación en la Sumativa 3
Nota del 1.er / 2° semestre = 0	495 / 650	14,2 / 18,7	Coincide con 0 unidades aprobadas; se trata como sin nota
Valores fuera de rango (edad, nota de admisión)	0	0,0	No requiere

La anomalía principal son los 152 estudiantes sin ninguna actividad académica en dos semestres: 75 figuran como graduados, lo que es imposible, de modo que son registros incompletos. Se excluyen en ambas clases porque atenúan todas las comparaciones (el *d* de Cohen de la Prueba 1 pasa de −1,77 a −1,94 al excluirlos). Quedan **3.478 estudiantes**, 1.344 desertores (38,6 %). Además, la nota de semestre igual a 0 ocurre exactamente cuando no se aprobó ninguna unidad (la menor nota positiva es 9,8), por lo que se reemplazó por "sin nota". El % de la Tabla 1 se calcula sobre los 3.630 estudiantes Dropout y Graduate en la primera fila y sobre los 3.478 analizados en el resto. La Figura 1 resume el objetivo y los faltantes.

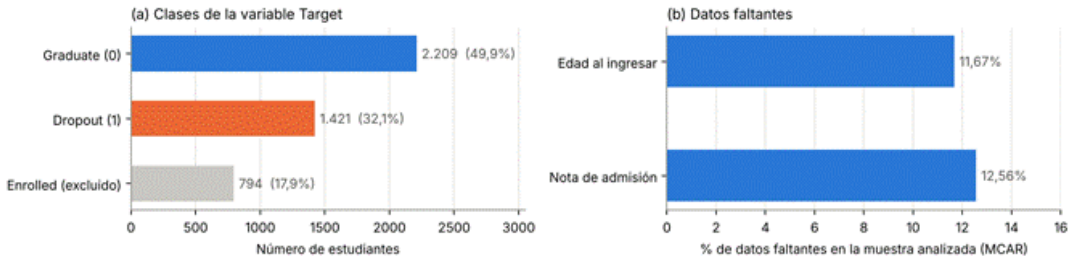


Figura 1. (a) Clases de Target; Enrolled se excluye. (b) Datos faltantes generados en la muestra analizada.

II. Análisis exploratorio de datos

A. Variables numéricas

Tabla 2. Medidas de tendencia central, dispersión y forma de las variables numéricas principales (n = 3.478). Notas de admisión y de formación previa en escala 0 a 200; nota de semestre en escala 0 a 20. Curt.: curtosis en exceso.

Variable		Media	Mediana	Desv. est.	V %	IC	ín.	áx.	sim.	urt.
Edad al ingresar (años)	.072	3,61	20,0	7,92	3,6	,0	7	0	,97	,72
Nota de admisión	.041	26,91	126,3	14,24	1,2	6,5	5	90	,47	,56
Nota de formación previa	.478	32,66	133,1	13,07	,9	5,0	5	90	,26	,89
Unid. aprobadas 1.er sem.	.478	,00	6,0	3,15	2,9	,0	0	6	,81	,40
Unid. aprobadas 2° sem.	.478	,72	5,0	3,08	5,4	,0	0	0	,25	,94
Nota 2° sem. (sin ceros)	.828	2,88	12,83	1,38	0,7	,91	0,0	8,6	,28	0,13
Tasa de desempleo (%)	.478	1,63	11,1	2,67	3,0	,5	,6	6,2	,19	1,00

La edad es muy asimétrica (1,97): la mitad ingresa con 20 años o menos, pero una cola que llega a 70 años eleva la media a 23,61, por lo que la mediana describe mejor al estudiante típico. Las unidades aprobadas tienen la mayor dispersión relativa (CV de 63 % a 65 %) y, como muestra la Figura 2, una distribución con dos grupos: 650 estudiantes sin unidades aprobadas en el 2° semestre y el resto concentrado entre 5 y 8. La nota de admisión y la nota de semestre (sin ceros) tienen formas cercanas a la simétrica. La curtosis (en exceso, 0 en una distribución normal) confirma estas formas: la edad (3,72) y las unidades aprobadas del 1.er semestre (3,40) tienen colas pesadas, por los estudiantes mayores y por unos pocos que aprueban más de 20 unidades; la tasa de desempleo es aplanada (−1,00) porque solo toma 10 valores, uno por cohorte de ingreso.

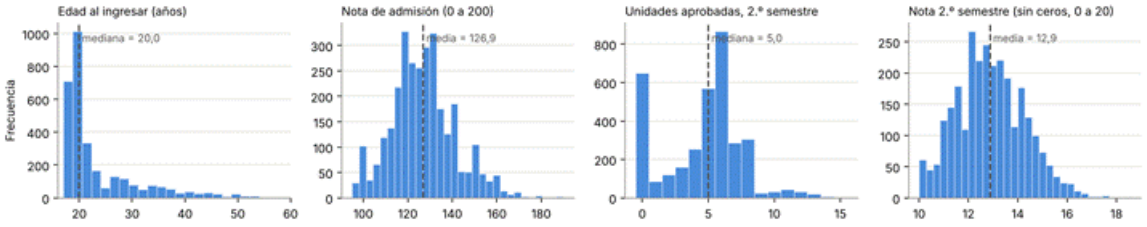


Figura 2. Histogramas de las variables numéricas principales, con su media o mediana de referencia.

B. Variables categóricas

La Figura 3a presenta las frecuencias relativas de las variables binarias: 88,3 % asiste en jornada diurna, 86,7 % tiene la matrícula al día, 33,4 % son hombres y 26,7 % tiene beca. En estado civil predominan los solteros (3.050; 87,7 %) y los casados (324; 9,3 %); el 67,6 % ingresó a su carrera de primera preferencia.

C. Análisis bivariado

La Figura 3b cruza cada factor con la deserción. Las mayores diferencias son financieras: deserta el 94,4 % de quienes no tienen la matrícula al día y el 75,3 % de los deudores. Le siguen la beca (13,1 % con beca y 48,0 % sin ella), el sexo (56,5 % en hombres y 29,7 % en mujeres), la jornada (50,7 % vespertina y 37,0 % diurna) y la condición de desplazado (32,7 % y 45,6 %). Las variables financieras pueden ser tanto causa como consecuencia del abandono, porque quien decide desertar deja de pagar.

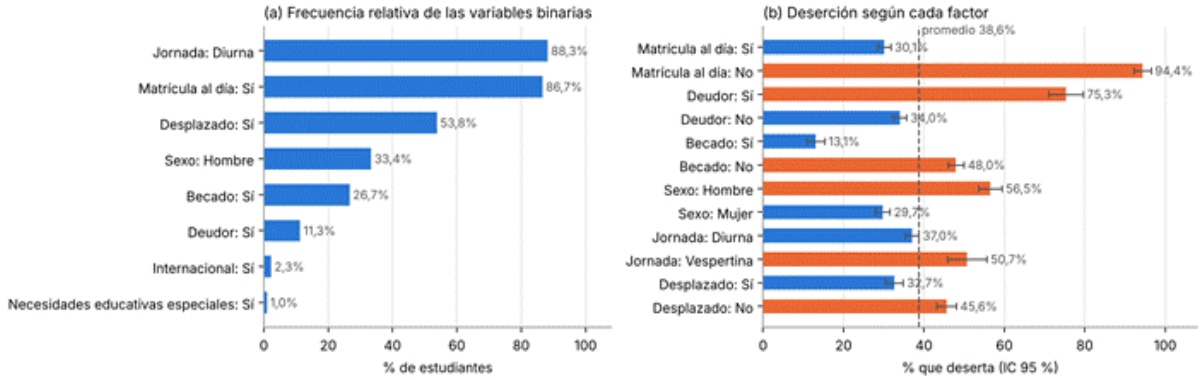


Figura 3. (a) Frecuencia relativa de las variables binarias. (b) Porcentaje de deserción por factor, con IC al 95 %.

En la matriz de correlaciones (Figura 4), el desempeño académico es lo más asociado a la deserción: unidades aprobadas del 2° semestre (r = −0,69) y del 1.er semestre (r = −0,58). Las notas, una vez excluidos los ceros, se asocian menos (r = −0,33): pesa más cuántas unidades se aprueban que con qué nota. La edad tiene una asociación positiva moderada (r = 0,29) y las variables macroeconómicas son prácticamente independientes del desenlace ($|r| \leq 0{,}05$), porque solo varían por cohorte. Las unidades aprobadas de ambos semestres están muy correlacionadas entre sí (r = 0,91), lo que anticipa multicolinealidad.

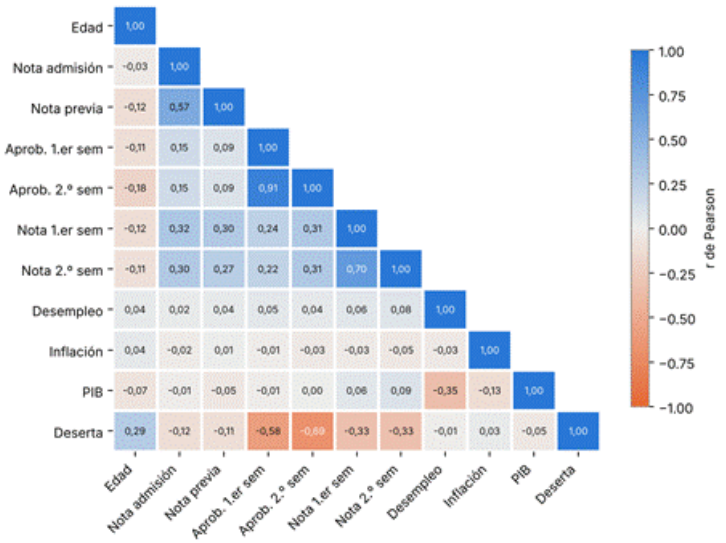


Figura 4. Matriz de correlaciones de Pearson (notas sin ceros; casos disponibles por par).

III. Estimación de parámetros

Se construyeron intervalos al 95 % para cuatro variables numéricas y la proporción de deserción (Tabla 3). Para las medias se usó la distribución t de Student, porque la desviación estándar poblacional es desconocida; con más de 3.000 casos, el Teorema Central del Límite respalda la normalidad aproximada de la media aunque las variables sean asimétricas. Para la proporción se usó la aproximación normal, válida porque hay más de 10 casos en cada categoría.

Tabla 3. Estimación puntual e intervalos de confianza al 95 %.

Parámetro	Estimación	IC 95 %	Método	n
Edad media al ingresar (años)	23,61	[23,33; 23,89]	t de Student	3.072
Nota de admisión media	126,91	[126,40; 127,41]	t de Student	3.041
Unidades aprobadas medias, 1.er sem.	5,00	[4,90; 5,11]	t de Student	3.478
Unidades aprobadas medias, 2° sem.	4,72	[4,61; 4,82]	t de Student	3.478
Proporción que deserta	38,64 %	[37,02 %; 40,26 %]	Normal	3.478

Interpretación. El 95 % es una propiedad del procedimiento, no de un intervalo en particular: si se repitiera el muestreo muchas veces, el 95 % de los intervalos construidos de esta forma contendría el parámetro real. El intervalo obtenido para la deserción, [37,02 %; 40,26 %], lo contiene o no; lo que se sabe es que proviene de un método que acierta 95 de cada 100 veces, y que su amplitud (3,2 puntos) refleja la precisión que da una muestra de 3.478 casos. Las unidades aprobadas medias del 2° semestre se estiman entre 4,61 y 4,82, pero esa media mezcla grupos muy distintos: 2,05 unidades en los desertores (IC 95 %: 1,91 a 2,19) y 6,39 en los graduados (6,31 a 6,48). Como verificación, la mediana de la nota de admisión se estimó por bootstrap (5.000 remuestras, semilla 42): 126,30, con IC 95 % de [125,60; 126,80].

Limitaciones. Los intervalos suponen una muestra representativa e independiente; los datos provienen de una sola institución, por lo que generalizar exige cautela. Al excluir a los Enrolled y los registros sin actividad, la proporción corresponde a quienes tienen un desenlace y actividad registrada, no a toda la matrícula. La media de la edad está inflada por la cola de estudiantes mayores y debe leerse junto con la mediana (20 años). Edad y nota de admisión usan el 88 % de los casos: como los faltantes son aleatorios, esto reduce la precisión pero no sesga.

IV. Pruebas de hipótesis

Se usó $\alpha = 0{,}05$, valor convencional en estudios aplicados que equilibra los errores de tipo I y II. Como cada prueba usa más de 3.000 observaciones, valores *p* muy pequeños son esperables; por eso se informa también el tamaño del efecto.

A. Prueba 1: unidades aprobadas en el 2° semestre

H_0: μ Dropout = μ Graduate; H_1: μ Dropout ≠ μ Graduate. **Supuestos:** grupos independientes (cada fila es un estudiante distinto) y grandes (1.344 y 2.134), por lo que el Teorema Central del Límite compensa la asimetría (1,39 y 2,28). La prueba de Levene rechaza la igualdad de varianzas (estadístico 179,7; $p < 0{,}0001$), así que se usa la *t* de Welch (Welch, 1947). **Resultado:** medias de 2,05 y 6,39; diferencia de −4,34 unidades (IC

95 %: −4,51 a −4,18), t = −52,33, 2.311 grados de libertad, p < 0,0001. Se rechaza H_0, con un efecto muy grande (d = −1,94), confirmado por la prueba de Mann-Whitney (p < 0,0001; medianas 1 y 6). **Implicancia:** las unidades aprobadas al cierre del primer año son una señal temprana y fuerte para priorizar tutorías.

B. Prueba 2: matrícula al día y deserción

H_0: p atrasada = p al día; H_1: p atrasada ≠ p al día. Se usa la prueba z de dos proporciones con la proporción combinada. **Supuesto:** al menos 26 casos de cada desenlace por grupo, suficiente para la aproximación normal. **Resultado:** deserta el 94,4 % de quienes tienen la matrícula atrasada (462) y el 30,1 % de quienes la tienen al día (3.016); diferencia de 64,3 puntos porcentuales (IC 95 %: 61,6 a 66,9), z = 26,42, p < 0,0001, riesgo relativo 3,13. Es la mayor diferencia de proporciones del conjunto. **Implicancia:** es la alerta más nítida, pero puede ser consecuencia del abandono; sirve para detectar, no para explicar.

C. Prueba 3: beca y deserción

H_0: beca y deserción son independientes; H_1: están asociadas. Ambas variables son cualitativas: prueba χ^2 de independencia sobre la tabla de 2 × 2. **Supuesto:** frecuencia esperada mínima de 359. **Resultado:** deserta el 13,1 % de los becados (122 de 930) y el 48,0 % de quienes no tienen beca (1.222 de 2.548); χ^2 = 348,82, 1 grado de libertad, p < 0,0001; V de Cramér = 0,32, riesgo relativo 3,66, razón de momios 6,10. **Implicancia:** la situación económica pesa en el abandono; al ser observacional no prueba que la beca lo evite, pero respalda incluir el apoyo financiero en las alertas.

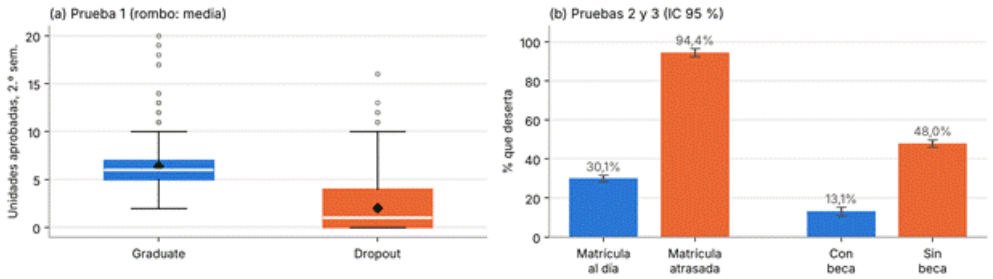


Figura 5. (a) Unidades aprobadas en el 2° semestre por grupo. (b) Deserción según matrícula y beca, con IC al 95 %.

V. Informe de avance del proyecto

Problema y métodos. Una institución con recursos limitados debe decidir a qué estudiantes priorizar antes de que abandonen; no detectar a uno en riesgo cuesta más que apoyar a quien no lo necesitaba. Se aplicó estadística descriptiva por tipo de variable, análisis bivariado, intervalos de confianza (t de Student, aproximación normal y *bootstrap*) y tres pruebas de hipótesis con supuestos verificados y tamaño del efecto.

Resultados e interpretación. El rendimiento del primer año es la señal más fuerte (los desertores aprueban 4,34 unidades menos en el 2° semestre); la matrícula atrasada concentra la mayor diferencia de proporciones y la falta de beca triplica el riesgo. Un hallazgo metodológico: el χ^2 que comprueba si los faltantes de la nota de admisión son independientes de Target dio p = 0,041, aunque sabemos que son MCAR porque los generamos al azar. Es un **error tipo I demostrado**: al repetir la generación con 1.000 semillas, el 5,6 % de los χ^2 dio p < 0,05, el nivel nominal. Por eso un p = 0,041 aislado no basta para concluir que unos faltantes reales no son MCAR: se hicieron dos pruebas (umbral

de Bonferroni 0,025), el efecto es mínimo (V = 0,04) y la prueba solo puede descartar MCAR, no confirmarlo.

Próximos pasos. Imputar los faltantes y medir el error contra los valores originales; aplicar simulación y remuestreo (Sumativa 2); y construir modelos de regresión logística sin incluir juntas variables muy correlacionadas, como las unidades aprobadas de ambos semestres (Sumativa 3).

VI. Notebook y repositorio GitHub

El análisis se hizo en Python con pandas (McKinney, 2010), numpy, scipy (Virtanen et al., 2020) y matplotlib. El repositorio GitHub enlazado en la portada contiene los datos, el cuaderno `00_generacion_faltantes.ipynb` (genera una sola vez los faltantes y guarda los originales) y el cuaderno `02_sumativa1_analisis_exploratorio_inferencial.ipynb`, que sigue el orden de este informe y produce todas sus tablas, pruebas, la simulación y las figuras. Ambos fijan la semilla 42 y, ejecutados desde cero, reproducen los mismos resultados.

VII. Bibliografía

Maidana, J. P. (2026). Bases de datos disponibles para el proyecto del curso [Apunte]. Universidad Andrés Bello.

McKinney, W. (2010). Data structures for statistical computing in Python. En Proceedings of the 9th Python in Science Conference (pp. 56–61). https://doi.org/10.25080/Majora-92bf1922-00a

Realinho, V., Vieira Martins, M., Machado, J. y Baptista, L. (2021). Predict students' dropout and academic success [Conjunto de datos]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., ... SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. Nature Methods, 17(3), 261–272. https://doi.org/10.1038/s41592-019-0686-2

Welch, B. L. (1947). The generalization of "Student's" problem when several different population variances are involved. Biometrika, 34(1–2), 28–35. https://doi.org/10.1093/biomet/34.1-2.28