MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Formativa 1

Análisis Exploratorio e Inferencial (práctica)

Título del proyecto:	Evaluación del Riesgo de deserción vs graduación
Integrantes:	Matías Manriquez Ortiz Daniel Pérez Ramírez Abigail Robles Chávez Roberto Sánchez Saldivia
Dataset:	Predict Students Dropout and Academic Success
Docente:	Jean Paul Maidana Gonzalez
Fecha:	10/10/2026
Repositorio GitHub:	https://github.com/MatiasManriquezO/MCDI501-grupo8

Índice

Índice 1
Introducción 3
Aplicación de estadística descriptiva 4
Estimación puntual e intervalos de confianza 7
Aplicación de una prueba de hipótesis 8
    Prueba 1: unidades aprobadas en el 2º semestre 8
    Prueba 2: matrícula al día y deserción 8
    Prueba 3: beca y deserción 8
    Prueba 4: condición de estudiante internacional y deserción 9
Documentación de procedimientos y resultados 10
Interpretación preliminar de resultados 10
Bibliografía 12

Introducción

Este informe trabaja con el conjunto de datos **Predict Students' Dropout and Academic Success** (UCI, 2021) que reúne la información de 4.424 estudiantes de pregrado de una institución de educación superior de Portugal, descritos por 36 variables demográficas, socioeconómicas, macroeconómicas y de desempeño académico en los dos primeros semestres. La variable Target registra la situación del estudiante al final de la duración normal de su carrera.

El problema de decisión es la detección temprana del riesgo de deserción. Una institución con recursos limitados de tutoría, apoyo económico y acompañamiento debe decidir a qué estudiantes priorizar, y debe hacerlo antes de que abandonen.

El conjunto original no tiene datos faltantes. El mismo apunte exige que, en ese caso, el equipo los genere antes de comenzar el análisis, porque la Sumativa 3 trabaja la imputación. Se eliminó al azar el 12 % de los valores de la nota de admisión y de la edad al ingresar (531 valores en cada una), con semilla 42 y bajo un mecanismo completamente aleatorio (MCAR). Los valores originales se guardaron aparte para medir más adelante el error de imputación. Todo el proyecto usa esta versión con faltantes.

Aunque todas las variables se guardan como números, 18 son categorías codificadas (Course = 9500 es una carrera, no una cantidad). Por eso se usan medias y pruebas t para las cuantitativas, y proporciones, pruebas z y χ^2 para las cualitativas.

Tabla 1. Clasificación de las 36 variables del conjunto de datos.

Tipo	nº	Variables
Cuantitativa continua	7	Nota de admisión, nota de la formación previa, nota del 1.er y del 2º semestre (0 a 20), tasa de desempleo, tasa de inflación, PIB
Cuantitativa discreta	11	Edad al ingresar; unidades curriculares de cada semestre: convalidadas, inscritas, evaluadas, aprobadas y sin evaluación
Cualitativa binaria	8	Jornada (diurna o vespertina), desplazado, necesidades educativas especiales, deudor, matrícula al día, sexo, becado, internacional
Cualitativa ordinal	1	Orden de preferencia de la postulación (0 a 6)
Cualitativa nominal	9	Estado civil, modalidad de postulación, carrera, formación previa, nacionalidad, nivel educativo y ocupación de la madre y del padre
Variable objetivo	1	Target: Dropout (1) o Graduate (0); Enrolled se excluye

Aplicación de estadística descriptiva

En el conjunto de datos no hay duplicados. La nota de semestre vale 0 exactamente cuando el estudiante no aprobó ninguna unidad (495 casos en el 1er semestre y 650 en el 2º; la menor nota positiva es 9,8): no es una nota real, por lo que sus medidas usan solo a quienes aprobaron alguna unidad.

Tabla 2. Medidas descriptivas de las variables cuantitativas (n = 3.478).

Variable	n	Media	Mediana	Desv. est.	CV %	RIC	Mín.	Máx.	Asim.
Edad al ingresar (años)	3.072	23,61	20,0	7,92	33,6	7,0	17	70	1,97
Nota de admisión (0 a 200)	3.041	126,91	126,3	14,24	11,2	16,5	95,0	190,0	0,47
Nota formación previa (0 a 200)	3.478	132,66	133,1	13,07	9,9	15,0	95,0	190,0	0,26
Unidades aprobadas 1er sem.	3.478	5,00	6,0	3,15	62,9	3,0	0	26	0,81
Unidades aprobadas 2º sem.	3.478	4,72	5,0	3,08	65,4	3,0	0	20	0,25
Nota 1er sem. (sin ceros)	2.983	12,82	12,75	1,35	10,6	1,88	9,8	18,9	0,30
Nota 2º sem. (sin ceros)	2.828	12,88	12,83	1,38	10,7	1,91	10,0	18,6	0,28
Tasa de desempleo (%)	3.478	11,63	11,1	2,67	23,0	4,5	7,6	16,2	0,19

La edad es la más asimétrica (1,97): la mitad ingresa con 20 años o menos, pero una cola hasta 70 años eleva la media a 23,61, así que la mediana describe mejor al estudiante típico. Las unidades aprobadas tienen la mayor dispersión relativa (CV de 63 % y 65 %): conviven quienes aprueban todo con quienes no aprueban nada. Las variables macroeconómicas solo toman 9 o 10 valores, porque dependen del año de ingreso. La Figura 1 muestra que las clases están moderadamente desbalanceadas (38,6 % de desertores).

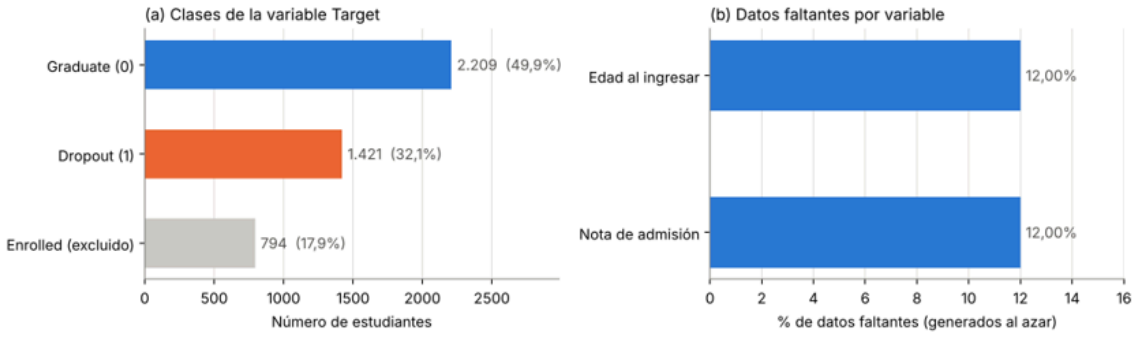


Figura 1. (a) Clases de la variable Target; Enrolled se excluye del análisis. (b) Porcentaje de datos faltantes generados en el conjunto completo.

En la Figura 2, la edad se concentra entre 18 y 20 años con una cola larga, la nota de admisión es casi simétrica y las unidades aprobadas del 2º semestre forman dos grupos: 650 estudiantes sin unidades aprobadas y el resto entre 5 y 8.

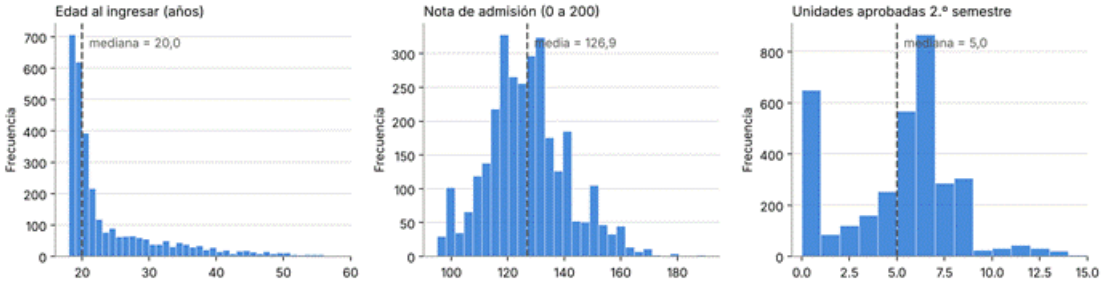


Figura 2. Distribución de la edad al ingresar, la nota de admisión y las unidades aprobadas en el 2º semestre.

Para las cualitativas se usan frecuencias (Tabla 3): la mayoría asiste de día y tiene la matrícula al día, un tercio son hombres y uno de cada cuatro tiene beca; el 87,7 % es soltero.

Tabla 3. Frecuencias de las variables cualitativas binarias (n = 3.478).

Variable	Categoría registrada	Frecuencia	%
Jornada	Diurna	3.070	88,3
Matrícula al día	Sí	3.016	86,7
Desplazado	Sí	1.870	53,8
Sexo	Hombre	1.163	33,4
Becado	Sí	930	26,7
Deudor	Sí	393	11,3
Internacional	Sí	80	2,3
Necesidades educativas especiales	Sí	36	1,0

En la Figura 3, los graduados aprueban en el 2º semestre una mediana de 6 unidades y los desertores, 1; los desertores ingresan además con más edad y mayor dispersión.

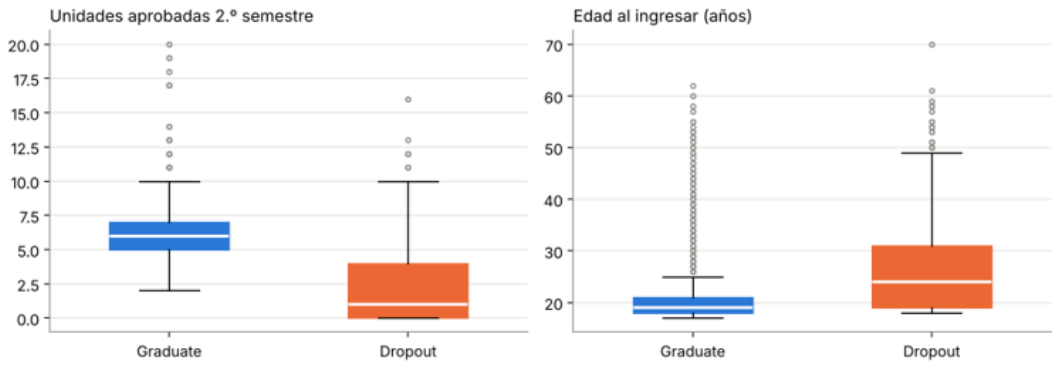


Figura 3. Unidades aprobadas en el 2º semestre y edad al ingresar, según el desenlace.

La matriz de correlaciones (Figura 4) confirma que el desempeño académico es lo más ligado a la deserción (unidades aprobadas: $r = -0{,}69$ en el 2º semestre y $-0{,}58$ en el 1.º), seguido de la edad ($r = 0{,}29$); las variables macroeconómicas casi no se relacionan ($|r| \leq 0{,}05$). Las unidades aprobadas de ambos semestres están correlacionadas entre sí ($r = 0{,}91$).

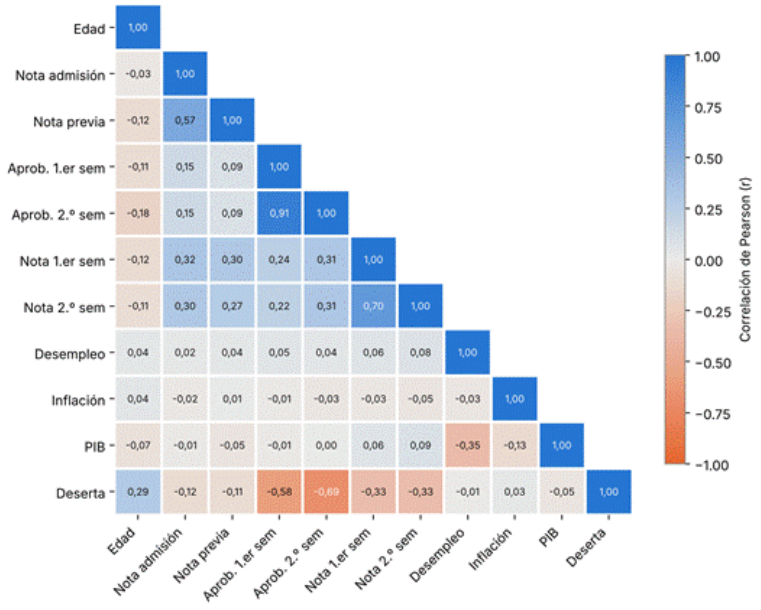


Figura 4. Matriz de correlaciones de Pearson. Las notas excluyen los ceros; cada par usa los casos disponibles.

La Figura 5 muestra la deserción según cinco factores. Las mayores diferencias son financieras (94,4 % con matrícula atrasada y 75,3 % entre deudores), seguidas de la beca (13,1 % con beca y 48,0 % sin ella), el sexo (56,5 % en hombres y 29,7 % en mujeres) y la jornada (50,7 % vespertina y 37,0 % diurna).

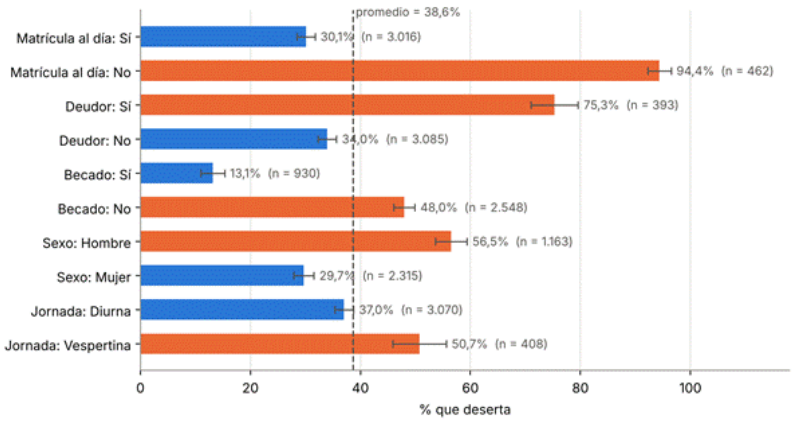


Figura 5. Porcentaje de deserción según factores cualitativos, con intervalos de confianza al 95 %. La línea marca el promedio (38,6 %).

Estimación puntual e intervalos de confianza

Se estimaron seis parámetros al 95 % (Tabla 4): las medias con *t* de Student, porque la desviación estándar poblacional es desconocida, y las proporciones con la aproximación normal, válida con más de 100 casos en cada categoría.

Tabla 4. Estimación puntual e intervalos de confianza al 95 %.

Parámetro	Estimación puntual	IC 95 %	n
Edad media al ingresar (años)	23,61	[23,33; 23,89]	3.072
Nota de admisión media	126,91	[126,40; 127,41]	3.041
Unidades aprobadas medias, 1.er semestre	5,00	[4,90; 5,11]	3.478
Unidades aprobadas medias, 2º semestre	4,72	[4,61; 4,82]	3.478
Proporción que deserta	38,64 %	[37,02 %; 40,26 %]	3.478
Proporción con beca	26,74 %	[25,27 %; 28,21 %]	3.478

Con un 95 % de confianza, entre 37,02 % y 40,26 % de quienes alcanzan un desenlace desertan: el valor real puede alejarse unos 1,6 puntos de la estimación puntual (38,64 %). Los intervalos de las medias son estrechos por el tamaño de la muestra. Como verificación, la mediana de la nota de admisión se estimó por *bootstrap* (5.000 remuestras, semilla 42): 126,30 [125,60; 126,80]; el *bootstrap* de la media coincide con el intervalo *t* ([126,40; 127,41]).

Los datos vienen de una sola institución, lo que limita la generalización; la proporción corresponde a quienes ya tienen desenlace, no a toda la matrícula; y edad y nota de admisión usan el 88 % de los casos, lo que reduce la precisión pero no sesga, porque los faltantes son aleatorios.

Aplicación de una prueba de hipótesis

Se aplicaron cuatro pruebas con α = 0,05, el valor convencional (5 % de riesgo de rechazar una hipótesis nula verdadera). Con más de 3.000 observaciones los valores *p* tienden a ser muy pequeños, por lo que cada resultado se acompaña de su tamaño del efecto. El procedimiento se eligió según el tipo de variable.

Prueba 1: unidades aprobadas en el 2º semestre

H_0: μ Dropout = μ Graduate, frente a H_1: μ Dropout ≠ μ Graduate (una variable cuantitativa, dos grupos independientes). **Supuestos:** cada fila es un estudiante distinto; Levene rechaza la igualdad de varianzas (179,7; $p < 0,0001$), por lo que se usa la *t* de Welch, y con más de 1.300 casos por grupo el Teorema Central del Límite compensa la falta de normalidad. **Resultado:** 2,05 frente a 6,39 unidades; diferencia de −4,34 (IC 95 %: −4,51 a −4,18), $t = -52,33$, 2.311 grados de libertad, $p < 0,0001$. Se rechaza H_0 con un efecto muy grande (*d* de Cohen = −1,94); sin excluir los 152 registros sin actividad habría sido −1,77.

Prueba 2: matrícula al día y deserción

Prueba *z* de dos proporciones: H_0: p atrasada = p al día, frente a H_1: p atrasada ≠ p al día; el supuesto se cumple (al menos 26 casos de cada desenlace por grupo). Deserta el 94,4 % de quienes tienen la matrícula atrasada (462) y el 30,1 % de quienes la tienen al día (3.016): 64,3 puntos de diferencia (IC 95 %: 61,6 a 66,9), $z = 26,42$, $p < 0,0001$. Es la mayor diferencia de proporciones del conjunto, aunque el pago atrasado puede ser consecuencia de la decisión de abandonar.

Prueba 3: beca y deserción

Prueba χ^2 de independencia (dos variables cualitativas); H_0: beca y deserción son independientes. Supuesto: frecuencia esperada mínima de 359. Deserta el 13,1 % de los becados (122 de 930) y el 48,0 % de quienes no tienen beca (1.222 de 2.548); $\chi^2 = 348{,}82$, 1 grado de libertad, $p < 0{,}0001$. Se rechaza H_0: riesgo relativo 3,66 y V de Cramér 0,32 (asociación moderada).

Prueba 4: condición de estudiante internacional y deserción

Deserta el 35,0 % de los internacionales (28 de 80) y el 38,7 % de los nacionales; $\chi^2 = 0{,}46$, $p = 0{,}498$: no se rechaza H_0, pero esto **no permite concluir que no haya asociación**. Con solo 80 internacionales, la potencia (probabilidad de detectar una diferencia que sí existe) es de 10 % para la diferencia observada; una diferencia real de 10 puntos se detectaría solo el 45 % de las veces, y recién con 20 puntos la potencia llega a 96 %. La prueba no es concluyente: los datos no alcanzan para responder.

Documentación de procedimientos y resultados

El análisis se hizo en Python (pandas, numpy, scipy, matplotlib) y está en el repositorio GitHub del proyecto: *00_generacion_faltantes.ipynb* genera una sola vez los faltantes, guarda los originales y comprueba el mecanismo MCAR; *01_formativa1_eda_inferencia.ipynb* reproduce todas las tablas, pruebas, la simulación y las figuras. Ambos usan la semilla 42 (Tabla 5).

Tabla 5. Procedimientos estadísticos aplicados.

Etapa	Procedimiento	Implementación en Python
Preparación	Objetivo binario Dropout (1) frente a Graduate (0); exclusión de Enrolled y de 152 registros sin actividad académica	pandas: isin(), filtro de filas
Preparación	Faltantes MCAR: 12 % en nota de admisión y edad, semilla 42	numpy.random.default_rng(42).choice
Descriptiva	Media, mediana, desviación, CV, RIC y asimetría; frecuencias	mean(), median(), std(), quantile(), skew(), value_counts()
Estimación	IC con t de Student y aproximación normal; bootstrap de la mediana (5.000 remuestras)	scipy.stats.t / norm; numpy.random.default_rng(42)
Hipótesis	Levene, t de Welch y d de Cohen	scipy.stats.levene, scipy.stats.ttest_ind(equal_var=False)
Hipótesis	z de dos proporciones; χ^2 de independencia, V de Cramér y riesgo relativo	fórmula con scipy.stats.norm; scipy.stats.chi2_contingency
Hipótesis	Potencia de la prueba de dos proporciones (h de Cohen)	función potencia_2prop con scipy.stats.norm
Simulación	Comprobación MCAR con χ^2 y 1.000 repeticiones de la generación de faltantes	numpy.random.default_rng(semilla), scipy.stats.chi2_contingency

Quedan registradas las siguiente decisiones: el objetivo binario sin Enrolled; la exclusión de los 152 registros sin actividad, con su efecto en los resultados; el uso de casos disponibles para los faltantes (por eso cada tabla informa su *n*); y el tratamiento de las notas en 0 como ausencia de nota.

Interpretación preliminar de resultados

El rendimiento del primer año es la mejor señal de alerta. Las unidades aprobadas separan con fuerza a desertores y graduados (d = −1,94) y ya en el 1er semestre se asocian con la deserción (r = −0,58): seguirlas al cierre de cada semestre permitiría intervenir a tiempo.

Las variables financieras muestran las diferencias más grandes, con cautela. La matrícula atrasada eleva la deserción de 30,1 % a 94,4 % y la falta de beca la triplica. La

beca es previa y respalda incluir el apoyo económico en las alertas; la matrícula impaga puede ser causa o consecuencia del abandono.

Un error tipo I demostrado con nuestros propios datos. El χ^2 que comprueba si los faltantes de la nota de admisión son independientes de Target dio $p = 0{,}041$, aunque sabemos que son aleatorios porque los generamos así: es un error tipo I. Al repetir la generación con 1.000 semillas, el 5,6 % de los χ^2 dio $p < 0{,}05$, el nivel nominal. Con datos reales, un $p = 0{,}041$ aislado tampoco bastaría para concluir que no son MCAR: ocurre en 1 de cada 20 pruebas, se hicieron dos (umbral de Bonferroni 0,025), el efecto es mínimo (V de Cramér = 0,04) y la prueba solo puede descartar MCAR, no confirmarlo.

Un *p* alto no demuestra ausencia de efecto. Con una potencia de 10 %, el resultado de la prueba de internacionales es esperable aunque exista una diferencia; leerlo como "no hay asociación" sería un error tipo II no reconocido.

Advertencias para las siguientes fases. Las unidades aprobadas de ambos semestres ($r = 0{,}91$) no deben entrar juntas a un modelo sin revisar la multicolinealidad; las variables macroeconómicas varían solo por cohorte; y los datos son observacionales: describen asociaciones, no causas.

Bibliografía

Maidana, J. P. (2026). Bases de datos disponibles para el proyecto del curso [Apunte]. Universidad Andrés Bello, Santiago, Chile.

Maidana, J. P. (2026). Tipos de variables y exploración de datos con pandas [Apunte]. Universidad Andrés Bello, Santiago, Chile.

McKinney, W. (2010). Data structures for statistical computing in Python. Proceedings of the 9th Python in Science Conference, 56–61.

Realinho, V., Vieira Martins, M., Machado, J. y Baptista, L. (2021). Predict students' dropout and academic success [Conjunto de datos]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success

Virtanen, P., et al. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. Nature Methods, 17, 261–272.