MAGÍSTER EN CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL

MCDI501: Estadística Computacional para la Toma de Decisiones

Evaluación Sumativa 2

Validación, Simulación y Métodos de Remuestreo

Informe técnico grupal · 20 %

Título del proyecto:	Evaluación del riesgo de deserción frente a graduación
Integrantes:	Grupo 8: Matias Manriquez Ortiz, Daniel Pérez Ramírez, Abigaíl Robles Chávez, Roberto Sánchez Saldivia
Dataset:	Predict Students' Dropout and Academic Success (UCI, 2021)
Docente:	Jean Paul Maidana Gonzalez
Fecha:	18/10/2026
Repositorio GitHub:	https://github.com/MatiasManriquezO/MCDI501-grupo8

Información de la evaluación	
Fase del proyecto:	Fase 3: Desarrollo del proyecto
Modalidad:	Grupal
Ponderación:	20 % de la nota final
Entregables:	Informe PDF (máx. 7 págs.) · Notebook .ipynb · Repositorio GitHub (carpetas S1, S2 y archivo de resultados validados)
Resultado de aprendizaje:	RA2: implementar métodos computacionales de simulación y remuestreo para apoyar la toma de decisiones en escenarios complejos.
Indicadores:	ID2.1, ID2.2, ID2.3
Prerrequisito:	Sumativa 1 completada (usarán sus resultados).

Índice

Índice **2**
I. Validación de resultados de S1 mediante bootstrap **3**
II. Validación de pruebas de hipótesis mediante permutación **3**
III. Evaluación de estabilidad de correlaciones **4**
IV. Simulación Monte Carlo basada en parámetros de S1 ..... **5**
A. Análisis de sensibilidad **5**
V. Análisis de robustez **6**
VI. Preparación para la Sumativa 3 ..... **7**
VII. Bibliografía (APA 7) **7**

I. Validación de resultados de S1 mediante bootstrap

Se aplicó *bootstrap* no paramétrico (Efron y Tibshirani, 1993) con **10.000 remuestras** a cuatro parámetros estimados en S1: edad media, nota de admisión media, unidades aprobadas medias del 2.º semestre y proporción que deserta. Con la misma distribución *bootstrap* se calcularon el intervalo **percentil** y el **BCa**, que corrige el sesgo (z_0) y la asimetría o aceleración (a, estimada por *jackknife*) (Efron, 1987), comparándolos con el clásico de S1 (Tabla 1). El clásico supone normalidad de la media (Teorema Central del Límite, TCL); el percentil, que la distribución *bootstrap* está centrada y es simétrica; el BCa relaja ambos supuestos.

Tabla 1. Intervalos de confianza al 95 %: clásico de S1, percentil y BCa (10.000 remuestras).

Parámetro	Estimación	Clásico (S1)	Percentil	BCa	EE clásico / bootstrap
Edad media (años)	23,61	[23,33; 23,89]	[23,33; 23,90]	[23,33; 23,90]	0,143 / 0,144
Nota de admisión media	126,91	[126,40; 127,41]	[126,39; 127,41]	[126,39; 127,41]	0,258 / 0,261
Unidades aprobadas, 2.º sem.	4,72	[4,61; 4,82]	[4,61; 4,82]	[4,62; 4,82]	0,052 / 0,053
Proporción que deserta	38,64 %	[37,02; 40,26]	[37,06; 40,28]	[37,09; 40,31]	0,83 / 0,82 pp

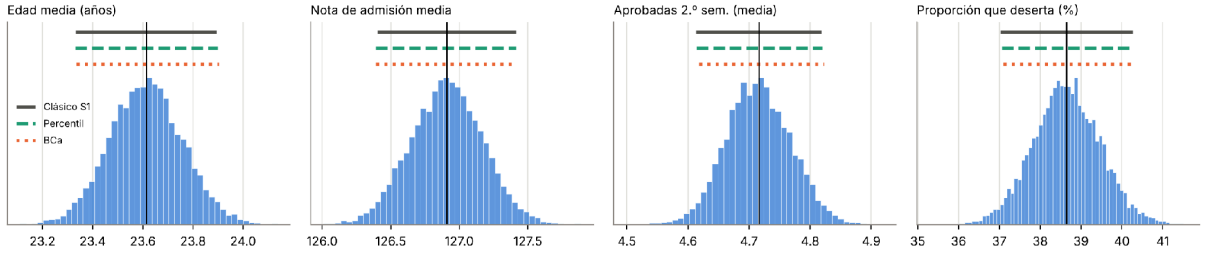


Figura 1. Distribuciones *bootstrap* de los cuatro parámetros con los intervalos clásico, percentil y BCa. La línea vertical marca la estimación de S1.

Discrepancias. Los tres intervalos coinciden: el BCa se aleja del clásico a lo más 0,009 años en la edad y 0,07 pp en la deserción, y el error estándar *bootstrap* replica el teórico. Incluso la edad (asimetría 1,97) da réplicas de la media casi simétricas (0,03; a = 0,006): con 3.072 casos el TCL ya opera. En la proporción y las aprobadas el BCa corrige un leve sesgo (z_0 = 0,014 y 0,033) que solo mueve el tercer decimal. **Confiabilidad.** Los intervalos clásicos de S1 quedan validados; el BCa sería preferible con muestras pequeñas o estadísticos que no son medias, como la mediana de la nota de admisión (S1, 5.000 remuestras: [125,60; 126,80]; con 10.000, percentil [125,70; 126,80] y BCa [125,90; 126,90]): por ser discreta, el método sí importa. El BCa propio se verificó contra `scipy.stats.bootstrap` y coincide.

II. Validación de pruebas de hipótesis mediante permutación

Se validaron dos pruebas de S1 y la comprobación MCAR con 10.000 permutaciones (Good, 2005). Bajo H_0 las etiquetas de grupo son intercambiables: se barajan, se recalcula el estadístico y el valor p es la proporción de réplicas al menos tan extremas como la observada, (k + 1)/(B + 1). En la Prueba 1 el estadístico es la diferencia de medias de unidades aprobadas (Dropout − Graduate); en la Prueba 3, la diferencia de proporciones de deserción (sin beca − con beca); en la comprobación MCAR, el χ^2 entre el faltante de la nota de admisión y Target (4.424 registros, tres clases).

Tabla 2. Valor *p* paramétrico de S1 frente al de permutación (10.000 permutaciones).

Prueba de S1	Observado	Rango nulo	*p* paramétrico	*p* permutación
Prueba 1: aprobadas 2.º sem.(*t* de Welch)	−4,34 unid.	[−0,37; 0,40]	< 0,0001	0,0001 (0 de 10.000)
Prueba 3: beca y deserción (χ^2)	34,8 pp	[−6,8; 7,1] pp	< 0,0001	0,0001 (0 de 10.000)
Comprobación MCAR (χ^2, 2 gl)	χ^2 = 6,40	[0,00; 16,47]	0,041	0,040 (396 de 10.000)

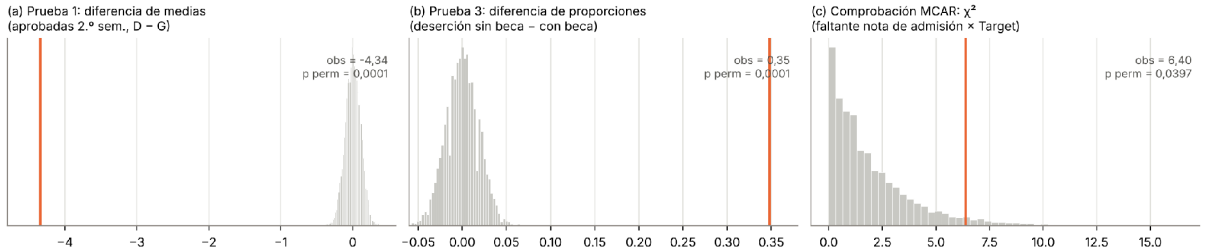


Figura 2. Distribuciones nulas de permutación. La línea naranja marca el valor observado.

Concordancia. En las Pruebas 1 y 3 ninguna permutación se acerca al valor observado (la nula queda en ±0,4 unidades y ±7 puntos, frente a −4,34 y 34,8). El *p* de permutación (0,0001, el mínimo posible) confirma el paramétrico sin suponer normalidad ni varianzas iguales. La MCAR es el caso exigente, porque su *p* está cerca de α: la permutación da 0,040 ± 0,004, igual al 0,041 de S1. Como los faltantes se generaron al azar, H_0 es verdadera y el resultado es un **error tipo I** y no un artefacto de la aproximación χ^2. **Método más apropiado:** con más de 3.000 casos ambos enfoques coinciden y el paramétrico basta; la permutación es preferible con grupos pequeños (p. ej., los 80 estudiantes internacionales de la Formativa 1).

III. Evaluación de estabilidad de correlaciones

Se evaluaron cinco correlaciones de Pearson de la matriz de S1 con intervalos *bootstrap* percentil al 95 % (10.000 remuestras de filas, casos disponibles por par). Con la variable objetivo binaria, el coeficiente es la correlación punto-biserial.

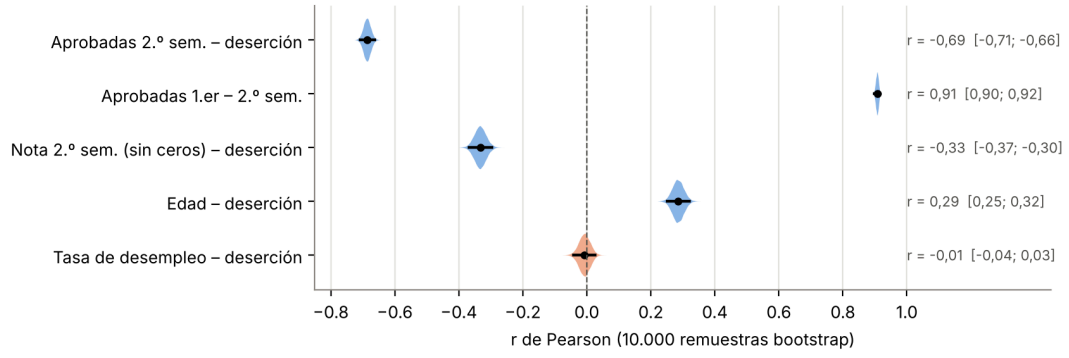


Figura 3. Distribuciones *bootstrap* de cinco correlaciones de S1 con su IC al 95 %. En naranja, la inestable.

Cuatro correlaciones son **robustas**: sus intervalos son estrechos (amplitud entre 0,02 y 0,07) y quedan lejos de cero. La más fuerte con la deserción, aprobadas del 2.º semestre (r = −0,69 [−0,71; −0,66]), es también la más estable: respalda usarla como señal temprana. La de aprobadas entre semestres (r = 0,91 [0,90; 0,92]) confirma que la multicolinealidad de S1 es real. La tasa de desempleo es **inestable**: su IC [−0,04; 0,03] incluye el cero, así que la "independencia" de S1 no prueba ausencia de relación.

IV. Simulación Monte Carlo basada en parámetros de S1

Escenario. La institución debe decidir cuántos cupos de tutoría reservar para una cohorte de ingreso; si planifica con el promedio y la cohorte resulta peor, quedan estudiantes en riesgo sin apoyo. Se modeló una cohorte de 1.000 estudiantes usando **solo parámetros de S1** (Prueba 3): cada estudiante tiene beca con probabilidad q = 0,2674 (930 de 3.478) y deserta con la tasa de su grupo, 13,12 % con beca (122 de 930) y 47,96 % sin beca (1.222 de 2.548). Se simularon **10.000 cohortes** (Robert y Casella, 2004) en dos versiones: con los parámetros fijos y propagando su incertidumbre, extrayéndolos en cada iteración de una distribución Beta con los conteos de S1.

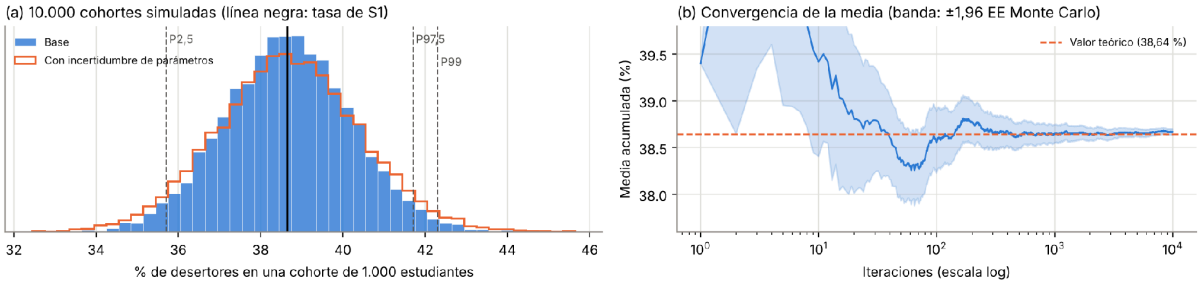


Figura 4. (a) Porcentaje de desertores en 10.000 cohortes simuladas, con percentiles 2,5; 97,5 y 99. (b) Convergencia de la media acumulada al valor teórico.

Resultados. La tasa media simulada (38,67 %) reproduce la de S1 (38,64 %). La media converge tras unas mil iteraciones; con 10.000, su error estándar Monte Carlo es 0,015 pp (Figura 4b). En el 95 % de las cohortes desertan entre 357 y 417 de cada 1.000, y en el peor 1 %, 423 o más. **Interpretación:** reservar 387 cupos (el promedio) falla en una de cada dos cohortes y en el 18,1 % desertan más de 400; 412 cupos cubren el 95 %. Propagando la incertidumbre de los parámetros, la dispersión sube de 1,53 a 1,73 puntos y el cupo al 95 % pasa a 415: estimarlos con una sola institución agrega un riesgo que el escenario fijo no muestra.

A. Análisis de sensibilidad

Tabla 3. Porcentaje de desertores simulado según el tamaño de la cohorte (10.000 simulaciones cada una).

Tamaño (N)	Media	Percentiles 2,5 – 97,5	Amplitud	Percentil 99	Cupos al 95 %
100	38,6 %	[29,0 %; 48,0 %]	19,0 pp	50,0 %	47
500	38,7 %	[34,4 %; 43,0 %]	8,6 pp	43,6 %	211
1.000	38,7 %	[35,7 %; 41,7 %]	6,0 pp	42,3 %	412
3.000	38,7 %	[37,0 %; 40,4 %]	3,4 pp	40,8 %	1.203

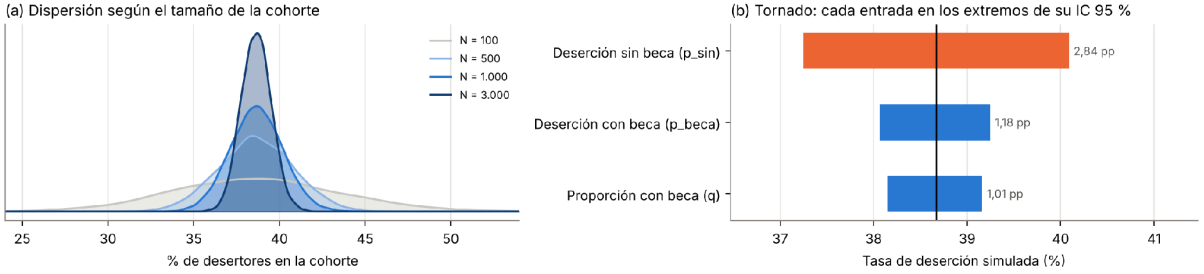


Figura 5. (a) Distribución simulada según el tamaño de la cohorte. (b) Tornado: tasa simulada al llevar cada parámetro a los extremos de su IC 95 % de S1.

La tasa esperada no cambia con el tamaño de la cohorte, pero su dispersión sí (Tabla 3): una cohorte de 100 necesita reservar cupos para el 47 % de sus estudiantes, y una de 3.000, para el 40,1 %; las carreras o sedes pequeñas requieren un margen proporcionalmente mayor. En el tornado (Figura 5b), la entrada más influyente es la deserción sin beca: recorrer su intervalo de S1 mueve la tasa simulada 2,84 puntos, frente a 1,18 de la deserción con beca y 1,01 de la cobertura de becas, por lo que es el parámetro que conviene estimar con más precisión. Como escenario exploratorio, si la cobertura de becas subiera del 26,7 % al 35 % o al 50 % y cada grupo mantuviera su tasa, la deserción esperada bajaría a 35,8 % y 30,6 % (81 desertores menos por cada 1.000). La asociación de S1 es observacional, así que este escenario cuantifica el potencial de la medida, no garantiza su efecto.

V. Análisis de robustez

Se evaluó la sensibilidad de los resultados de S1 frente a valores extremos, a la decisión de excluir registros, a faltantes y al supuesto de normalidad del intervalo *t*(Tabla 4).

Tabla 4. Sensibilidad de resultados de S1 a valores extremos, exclusiones, faltantes y supuestos.

Resultado de S1	Prueba de sensibilidad	Valor en S1	Valor alternativo
Edad media (años)	Media recortada al 5 % / sin el 1 % superior / mediana	23,61	22,57 / 23,31 / 20,0
Edad media (años)	Error estándar *jackknife*; obs. más influyente (70 años)	EE 0,143	EE 0,143; cambia 0,015
d de Cohen, Prueba 1	Incluyendo los 152 registros sin actividad	−1,94	−1,77
Deserción sin / con beca	Incluyendo los 152 registros sin actividad	48,0 % / 13,1 %	48,4 % / 13,8 %
Edad media (años)	Casos disponibles frente a valores originales	23,61 (n = 3.072)	23,60 (n = 3.478)
Nota de admisión media	Casos disponibles frente a valores originales	126,91 (n = 3.041)	126,91 (n = 3.478)
Cobertura del IC *t* (edad)	Datos sintéticos, n = 3.072 / 100 / 30 / 15	95 % nominal	95,0 / 93,8 / 92,0 / 89,2 %

Valores extremos. La media de la edad es sensible a la cola de 186 estudiantes de 40 años o más: recortar el 5 % la baja a 22,57 años y la mediana es 20. Ningún estudiante aislado la mueve (la observación más influyente, 70 años, la cambia en 0,015) y el error estándar *jackknife* coincide con el clásico, de modo que el problema no es la precisión sino la representatividad: la media no describe al estudiante típico. **Exclusiones.** Incluir los 152 registros sin actividad atenúa el efecto de la Prueba 1 (*d* de −1,94 a −1,77) y apenas mueve las tasas por beca; las conclusiones se mantienen. **Faltantes.** Las medias con casos disponibles difieren de las calculadas con los valores originales en 0,11 y 0,02 errores estándar: los faltantes MCAR reducen la precisión, pero no sesgan.

Datos sintéticos. Para comprobar si el intervalo *t* de S1 es confiable con una variable tan asimétrica, se generaron dos poblaciones sintéticas de un millón de edades: una paramétrica (Gamma ajustada por máxima verosimilitud) y otra por perturbación (edad observada más un ruido uniforme de ±0,5 años). La Gamma reproduce la media y la asimetría (2,06), pero no la forma: Kolmogorov-Smirnov la rechaza (D = 0,150; p < 0,001). La perturbación sí es fiel (D = 0,013; p = 0,947; distancia de Wasserstein 0,25 años). Con 10.000 muestras por tamaño, la cobertura real del intervalo *t* es 95,0 % con n = 3.072, pero cae a 92,0 % con n = 30 y a 89,2 % con n = 15, en ambas poblaciones. **Síntesis:** son confiables los intervalos y las pruebas de S1 con muestras grandes, la exclusión de los 152 registros y el tratamiento MCAR; requieren cautela la media de la edad como valor típico, la lectura de la tasa de desempleo y cualquier intervalo *t* en subgrupos pequeños.

VI. Preparación para la Sumativa 3

La Tabla 5 resume el estado de cada resultado de S1. El detalle completo se guarda en `data/processed/resultados_validados.csv`, que es la entrada directa de la Sumativa 3.

Tabla 5. Reporte de resultados validados para la Sumativa 3.

Resultado de S1	Validación en S2	Estado
Deserción 38,64 %; nota de admisión y aprobadas medias	Clásico, percentil y BCa coinciden; Monte Carlo la reproduce	Robusto
Edad media 23,61 años	IC estable, pero sensible a la cola; mediana 20	Cautela: usar mediana
Prueba 1 (aprobadas) y Prueba 3 (beca)	Permutación p = 0,0001; efecto estable sin los 152 registros	Robusto
Comprobación MCAR, p = 0,041	Permutación p = 0,040: error tipo I confirmado	Faltantes MCAR
Correlaciones de aprobadas, nota y edad con deserción	IC *bootstrap* estrechos que no incluyen 0	Robustas
Aprobadas 1.er – 2.º semestre (r = 0,91)	IC [0,90; 0,92]: multicolinealidad real	Robusta; no usar juntas
Tasa de desempleo – deserción	IC [−0,04; 0,03] incluye 0	Inestable
152 registros sin actividad; 186 edades ≥ 40	Influyentes identificados y documentados	Mantener exclusión

Recomendaciones para la Sumativa 3.

- Mantener Dropout frente a Graduate sin Enrolled ni los 152 registros (n = 3.478; 38,6 % de desertores).
- No incluir juntas las unidades aprobadas de ambos semestres en la regresión logística sin revisar el VIF; priorizar las del 2.º semestre, la correlación más fuerte y estable.
- Evaluar el modelo con y sin la matrícula al día, porque puede ser consecuencia del abandono (fuga de información).
- Transformar la edad (logaritmo o tramos) por su asimetría y su cola, y medir la imputación contra los valores originales.
- Justificar con el modelo el aporte de la tasa de desempleo, cuya asociación con la deserción no es estable.

VII. Bibliografía

Efron, B. (1987). Better bootstrap confidence intervals. *Journal of the American Statistical Association, 82*(397), 171–185. https://doi.org/10.1080/01621459.1987.10478410

Efron, B. y Tibshirani, R. J. (1993). *An introduction to the bootstrap*. Chapman & Hall.

Good, P. I. (2005). *Permutation, parametric, and bootstrap tests of hypotheses* (3.ª ed.). Springer.

Realinho, V., Vieira Martins, M., Machado, J. y Baptista, L. (2021). *Predict students' dropout and academic success* [Conjunto de datos]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success

Robert, C. P. y Casella, G. (2004). *Monte Carlo statistical methods* (2.ª ed.). Springer.

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., ... SciPy 1.0 Contributors. (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods, 17*(3), 261–272. https://doi.org/10.1038/s41592-019-0686-2